

[기술공통]

# 데이터 엔지니어링

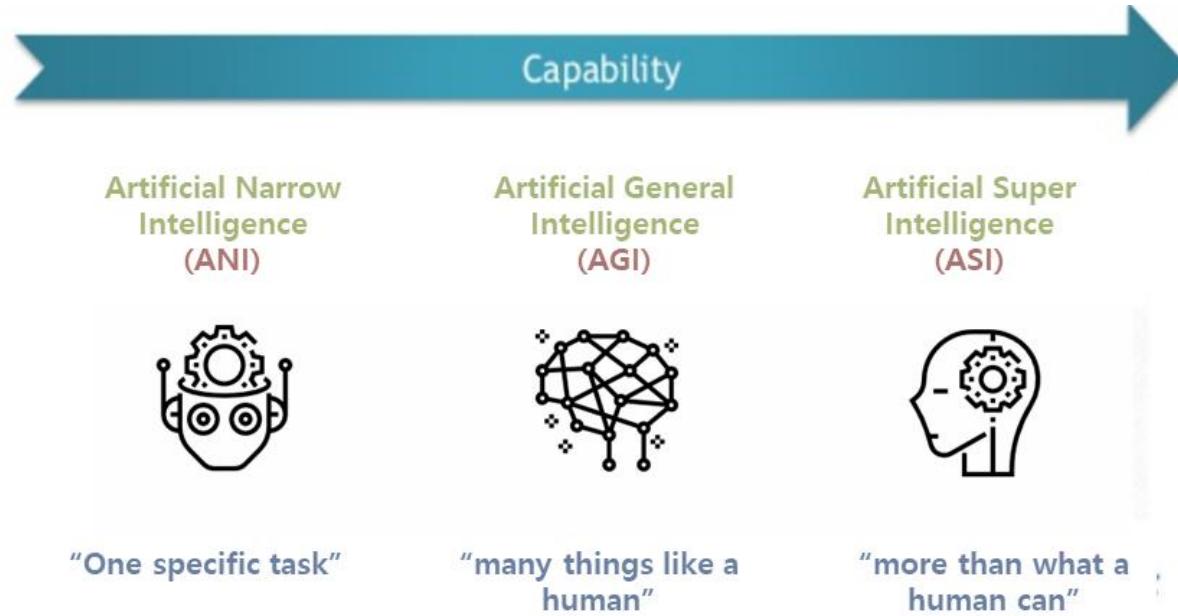


# Table of Contents

- I. DE 개요
- II. 자료구조와 파이썬 문법
- III. Numpy와 Pandas

# I. DE 개요

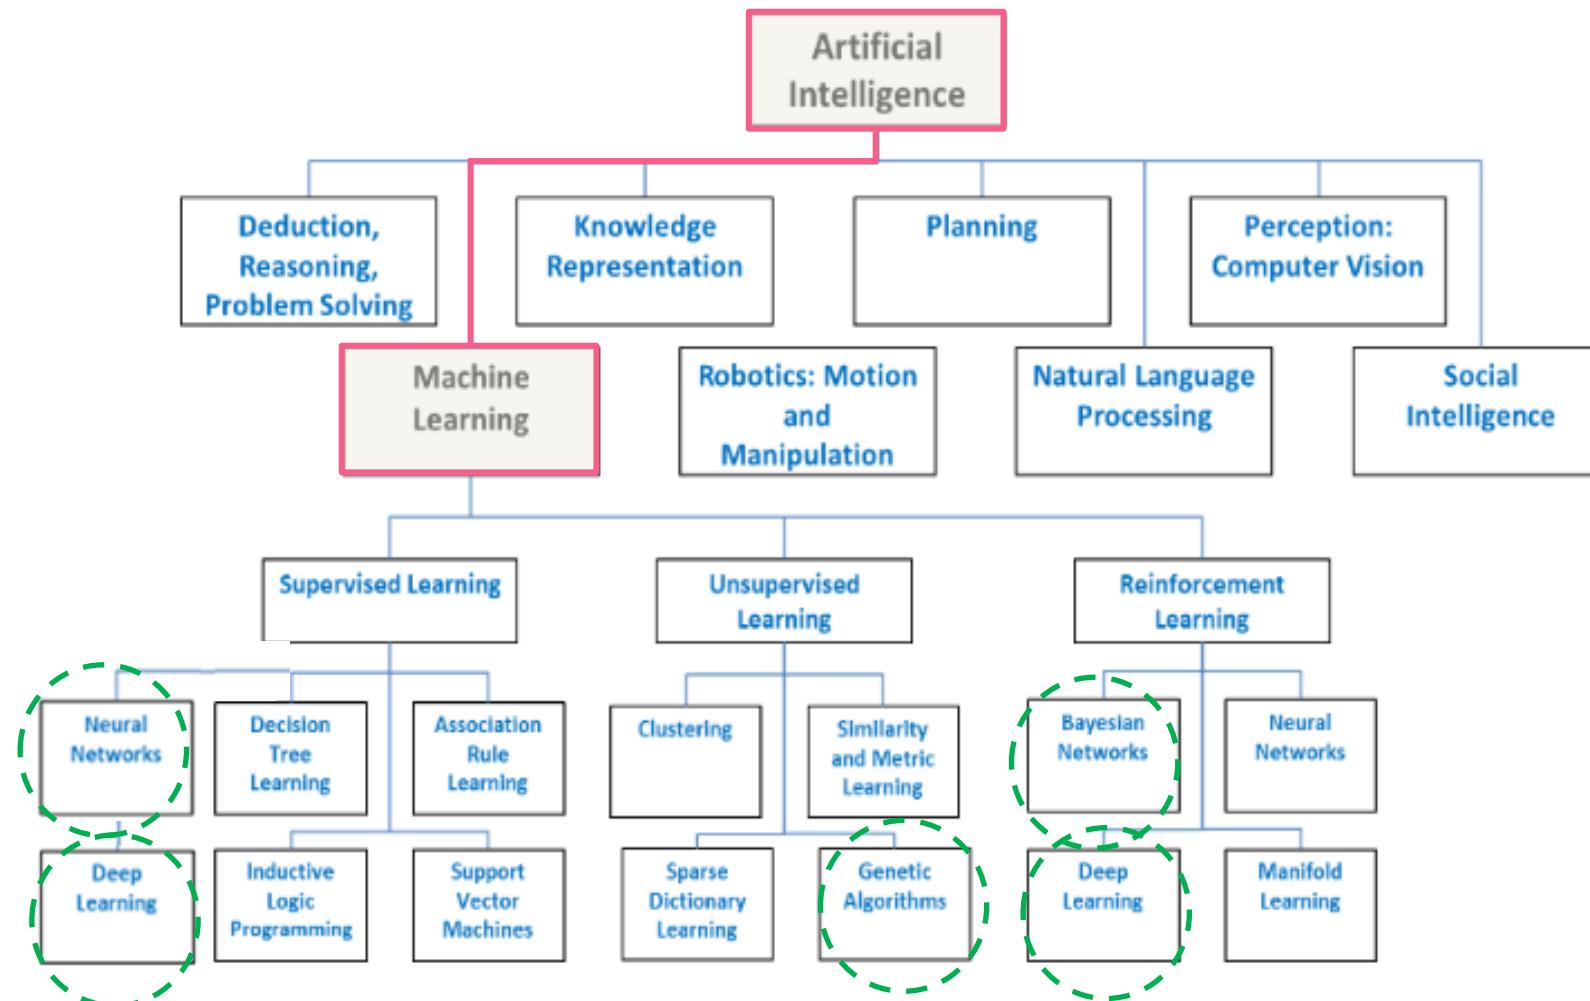
- AI



- '약인공지능(ANI)', '범용인공지능(AGI)', '초인공지능(ASI)'
- ANI: 주어진 데이터 내에서 주어진 문제를 해결하는 AI
- AGI로의 진입 가속화 중

# I. DE 개요

- AI



# I. DE 개요

## • Scaling Laws (Open AI, 2020)

- 컴퓨팅 리소스, 데이터, 모형 크기를 늘릴 수록 성능 개선
- 새로운 능력이 생겨남 (Emergent Abilities)





Figure 1: **Emergent abilities of large language models.** Model families display *sharp and unpredictable* increases in performance at specific tasks as scale increases. Source: Fig. 2 from [33].

# I. DE 개요

## • DX to AX: AI Transformation

### • AI 도입과 관련한 기업 의견 및 기술 활용도 인식

(단위: %; N=1,000)

구분	비중	구분	비중
기업 수요에 맞는 AI 기술 및 솔루션 부족	35.8	데이터 활용(개인정보 및 데이터 접근)	15.6
AI 기술 및 솔루션 개발 비용		성과 창출의 불확실성	11.2
전문인력 및 역량 부족	20.6	기타	1.0
	15.7	모름/무응답	0.1

\* 자료: KDI(2020)

(단위: %; N=738)

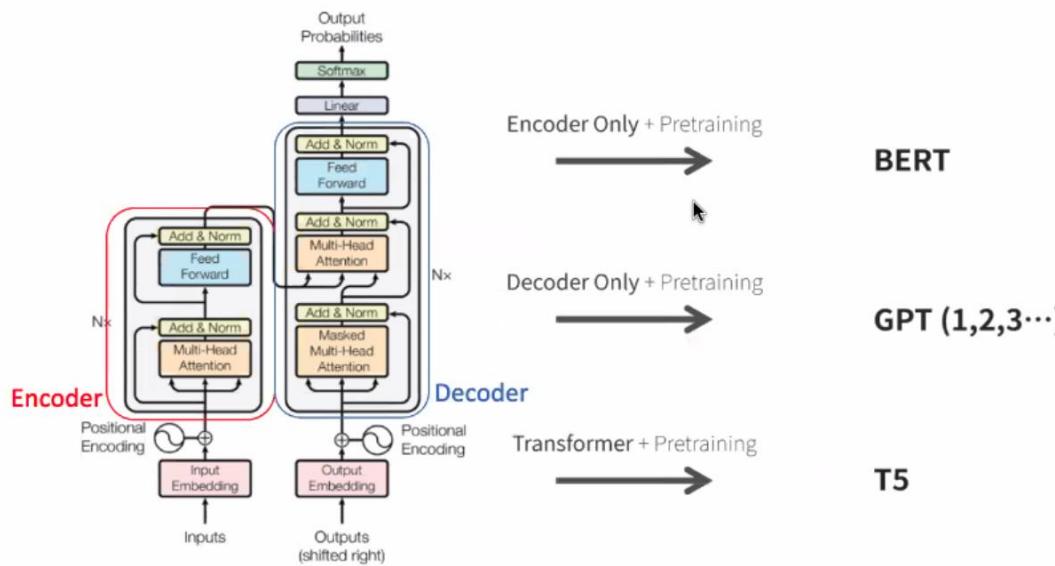
ID	세부 기술(토픽)	기술 활용도		수용 의사	기술 유용성		개발 시급성 정도	
		현재 활용도	미래 전망		성과 도움	경쟁력 제고	R&D 시급	국고 지원
1	자연어 이해 및 인식 처리 기술	54.7	64.8	51.9	60.3	64.6	58.1	56.5
2	인간 감정 분석 기술	49.2	58.8	45.5	54.2	57.9	51.4	50.1
3	지식 추론 기술	56.9	67.2	54.3	60.8	60.6	55.6	58.7
4	생성형 인공지능 기술	70.1	76.0	62.2	74.9	75.6	70.5	73.8
5	인공지능 신뢰성 기술	64.2	76.2	62.1	70.7	76.3	67.8	71.5
6	경로 탐색 및 모델 최적화	68.6	73.2	64.9	71.5	73.6	72.8	72.2
7	객체 감지 및 추적을 위한 비전 딥러닝 기술	66.8	77.5	65.9	70.7	71.7	73.4	74.1
8	그래프 분석 기반 진단 및 예측 기술	66.0	74.3	62.7	63.7	68.6	67.3	69.8
9	강화학습 기술	66.0	74.7	65.9	68.0	71.3	68.6	70.6
10	머신러닝 기반 데이터 보안 및 보호 기술	68.7	76.8	68.4	75.1	76.3	72.9	72.6
11	딥러닝 기반 이미지 분석 및 처리 기술	73.3	78.3	70.1	74.4	76.8	75.2	73.2
12	딥러닝 모델 알고리즘 및 성능 최적화	71.1	82.8	66.0	76.4	78.0	73.3	75.9

\* 주: 각 토픽별 최고값과 최저값의 항목을 각각 파란색, 주황색으로 표시함

# I. DE 개요

## • 간단하게 이해하는 LLM

- 언어모형: 주어진 문장을 구성하는 단어에 대한 확률을 모델링
- 주어진 문장/단어의 다음 단어를 예측, 문장 내 Masking한 단어를 예측
- 대용량 텍스트를 학습한 모형이 좋은 Representation(Embedding)을 보유



# I. DE 개요

## • 간단하게 이해하는 LLM


“오늘 저녁에는 어떤 메뉴를 먹을까요?”



오늘 : 0.5, 1.2, 0.3, ..., 0.9  
저녁에는 : 1.1, 0.2, 1.3, ..., 0.7  
어떤 : 1.5, 0.2, 0.9, ..., 0.5  
메뉴를 : 1.1, 1.7, 1.3, ..., 1.5  
먹을까요 : 1.12, 1.3, 1.7, ..., 1.1

Representation (Embedding)

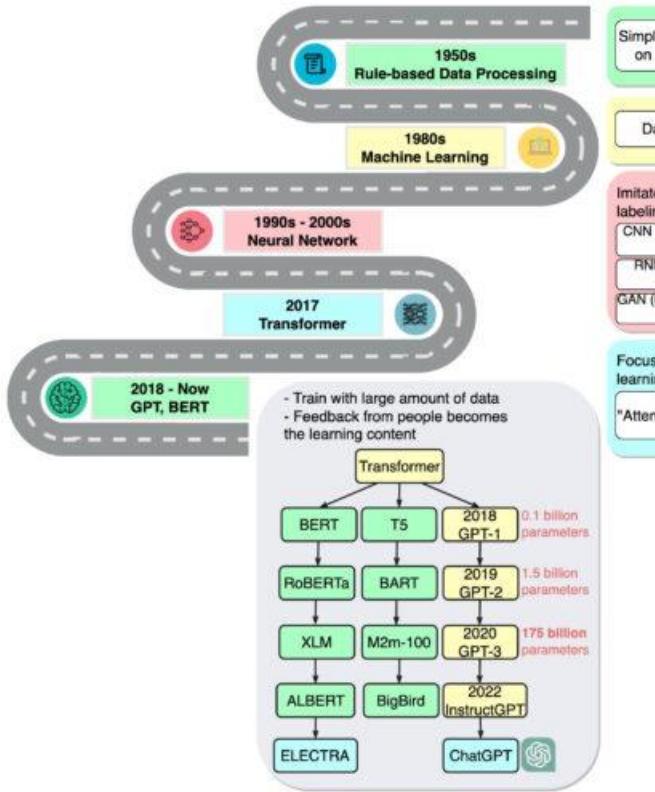
생성



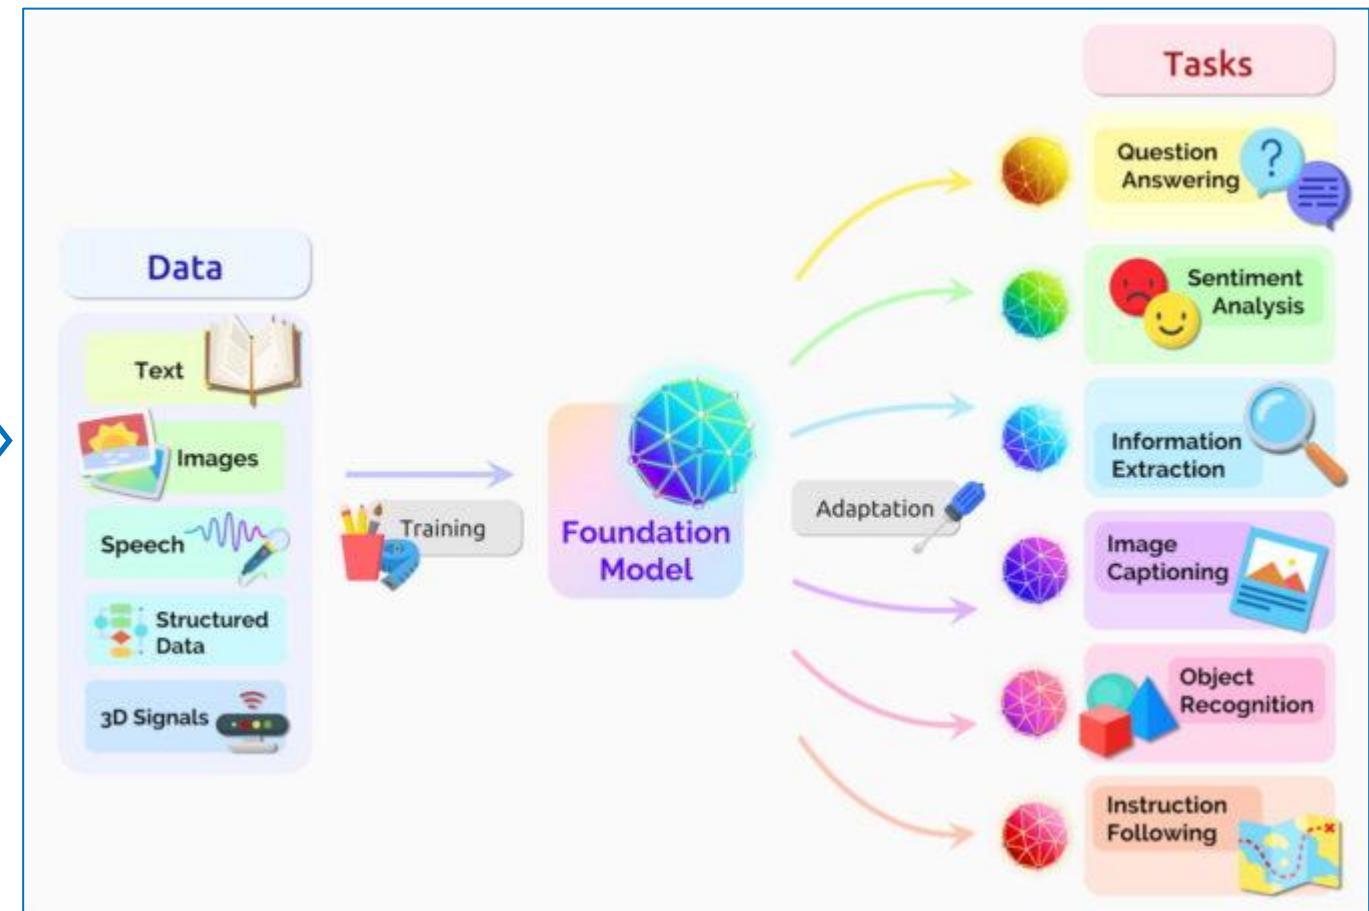
# I. DE 개요

## • Foundation Model

- 비지도학습을 통해 학습된 AI신경망
- 다양한 작업에 응용
- Open source LLM



Source: nvidia blog




Industrial Data Science Lab

- **RAG: 검색 증강 생성**

- Retrieval-Augmented Generation
- Hallucination을 줄이는 비용 효율적인 접근 방식
  - LLM의 기능을 특정 도메인이나 특정 기관의 내부 지식 기반으로 확장
  - LLM 외부의 데이터를 활용해서 보다 정확한 답변을 찾는 방안
  - 모형 학습을 다시 할 필요는 없음

# I. DE 개요

- RAG: 검색 증강 생성
- LLM 학습 데이터 외의 데이터인 외부 데이터 생성 후 임베딩을 통해 벡터DB저장
- 질문에 대한 관련 정보 검색
- 외부 데이터 업데이트: 실시간 및 배치 방식



## II. 자료구조와 파이썬 문법

### ➤ Python

- 1990년대 후반 Guido van Rossum이 개발 (네덜란드)
- 오픈소스 platform: General Public License (GPL)라이선스
- Python의 특징: High-level / Interactive / 객체지향 / Scripting 언어
- Easy-to-learn / Easy-to-read / Easy-to-maintain



TensorFlow 1.3 has arrived!

We're excited to announce the release of TensorFlow 1.3! Check out the release notes for all the latest.

[UPGRADE NOW](#)



Introducing TensorFlow Research Cloud

We're making 1,000 Cloud TPUs available for free to accelerate open machine learning research.

[LEARN MORE](#)



The 2017 TensorFlow Dev Summit

Thousands of people from the TensorFlow community participated in the first flagship event. Watch the keynote and talks.

[WATCH VIDEOS](#)

## II. 자료구조와 파이썬 문법

### ➤ 데이터 구조?

- 데이터를 일정한 기준에 의해 모아 놓은 것 (collection of data elements, structured in some way)

### ➤ List

- 여러 같은 type의 값을 하나의 객체로 모음
- 관련 함수: methods (object에 관련된 함수): len, max, min
- object.method(arguments) 방식으로 사용: lst.append(값), lst.count(값), lst.insert(위치, 값), lst.pop(), lst.reverse(), lst.remove(값), lst.sort()

## II. 자료구조와 파이썬 문법

### ➤ List

- 숫자형 값 또는 문자열 등 여러 값의 모임
  - indexing: Sequence 내의 element에 대해 순서 별 index로 접근
  - slicing: 일정 범위 내의 element를 access하는 것
- 값의 추가: 같은 type의 값을 추가

## II. 자료구조와 파이썬 문법

### ➤ Set

- list와 같은 값의 모임
- 값의 순서가 없음, 집합으로 이해
- { }로 생성

## II. 자료구조와 파이썬 문법

### ➤ Tuple

- 다른 형태의 sequence, list와 유사, 0 index에서 시작하는 값
- ( , , )로 표현
- Immutable sequence: 일단 생성 후에는 값을 변경할 수 없음. 문자열과 유사
- sort, append, reverse 등의 method는 사용 불가

### ➤ Dictionary

- 각 값마다 이름이 있는 값의 모음(A "bag" of values, each with its own label)
- 파이썬의 유용한 기능으로, key-value 구조를 지원
- Dictionary는 {}를 이용하여 생성 / 값으로는 key:value 쌍을 ,로 나열
- 빈 dictionary는 {}를 통해 생성

## II. 자료구조와 파이썬 문법

### ➤ 조건문과 반복문

- 조건문: 조건의 참/거짓여부에 따라 문장을 각각 실행, if else, if elif else를 사용
- 반복문: 파라미터 값을 변경하면서 동일한 작업을 여러 번 실행, for 사용
- 조건문-bool을 사용하여 조건 충족 여부 판단
- block은 {}로 표현하지 않고 indentation으로 표현(참고: 한 레벨당 공백 4개)

## II. 자료구조와 파이썬 문법

### ➤ 조건문과 반복문

```
var = 100
```

```
if var < 200:                                if에 대한 block
```

```
    print("Expression value is less than 200")
```

```
    if var == 150: } 하위 block
```

```
        print("Which is 150")
```

```
elif var == 50:
```

```
    print("Which is 50")
```

```
elif var < 50:
```

```
    print("Expression value is less than 50")
```

```
else:
```

```
    print("Could not find true expression")
```

## II. 자료구조와 파이썬 문법

### ➤ 조건문과 반복문

- 반복문-while과 for를 사용
- for: set/sequence(또는 iterable object(iterate 가능 객체)의 각 값에 대해 Code block 수행

```
x = 1
```

```
while x <=100:
```

```
    print(x)
```

```
    x+=1
```

```
words = ['this','is','a','wonder']
```

```
for word in words:
```

```
    print(word)
```

## II. 자료구조와 파이썬 문법

### ➤ 조건문과 반복문의 들여쓰기

- 같은 level의 statement들은 같은 들여쓰기(indentation)값을 갖아야 함

```
if a==1:  
    print(1)  
    print(0)
```

X

```
if a==1:  
    print(1)  
    print(0)
```

O

## II. 자료구조와 파이썬 문법

**분기(Branch):**

일방향적인 프로그램의 흐름이 어느 지점에서 2개 이상으로 나뉘게 됨

**if : 분기(branch)를 위한 명령어**

**사용 방법:**

**if 조건식:**

코드

코드



들여쓰기!

코드

### 조건문의 중첩

if 반짝이는 것 == 동전:

    if 반짝이는 것 == 500원짜리 동전:

        줍기

    if 반짝이는 것 < 500원짜리 동전:

        그냥 가던 길 가기

## II. 자료구조와 파이썬 문법

**else** 사용 방법:

**if** 조건식:

코드1

**else:**

코드2

True & True는 True  
True & False는 False  
False & True는 False  
False & False는 False

True | True는 True  
True | False는 True  
False | True는 True  
False | False는 False

여러 개의 조건식

**if** 조건식1 &(또는 |) 조건식2:

코드

**if** 조건식1 &(또는 |) 조건식2:

코드1

**else**

코드2

**if** 국어>90점 & 수학>90점:

피자

**Else:**

식빵

## II. 자료구조와 파이썬 문법

**for + if 사용**

- 2 1에서 선택된 값이 임시 변수에 임시로 할당
- 1 시퀀스 자료구조에서 값이 하나씩 선택됨

**for** 임시변수 **in** 시퀀스자료구조:

- 3 실행할 코드  
임시변수에 조건문을 적용

시퀀스 자료 구조의 모든 값이 다 사용될때 까지 이 과정이 반복

**for i in sales:**

**if i > 50:**

**들여쓰기!**

**print(i)**

**또 들여쓰기!**

## II. 자료구조와 파이썬 문법

### while 반복문

while 반복문은 조건식으로만 동작하며 반복할 코드 안에 조건식에 영향을 주는 변화식

사용방법

초기식

while 조건식:

반복할 코드

변화식

```
i = 0          # 초기식
while i < 10:    # while 조건식
    print('펭하 ')
    i = i +1    # 변화식
```

### For+리스트

```
a = [1,2,3,4]
result = []
for num in a:
    result.append(num*3)

print(result)
```



#### 사용방법:

[표현식 for 항목 in 반복가능객체 if 조건]

```
result = [num * 3 for num in a]
print(result)
```

```
result = [num * 3 for num in a if num % 2 == 0]
print(result)
```

### 함수(Function)

반복적으로 계속 사용되는 일정한 작업을 수행하는 코드들의 모음

함수: 함수이름( ) 의 형식으로 사용

예: 함수 객체 확인하는 함수  
globals()

함수의 입력과 출력

입력값없는 경우: 함수명()

입력값있는 경우: 함수명( 입력값, 입력값2, ...)

출력값 있는 경우: 함수 내 return을 통해 반환

결과값 받는 변수 = 함수명()

## II. 자료구조와 파이썬 문법

### ➤ 함수 정의

- def 라는 예약어와 함께 정의
- 함수의 사용은 함수명(입력값)의 형태

```
def Times(a,b):
```

```
    return a*b
```

- 함수 객체 확인: globals()
- return 없으면 None 반환

```
def setValue( newValue):
```

```
    x=newValue
```

```
retval = setValue(10)
```

```
print(retval)
```

### 모듈, 패키지, 라이브러리

모듈: 특정 기능을 .py 파일 단위로 작성

패키지: 특정 기능과 관련된 여러 모듈을 묶음. 패키지는 모듈에 네임스페이스 (namespace, 이름공간)를 제공

네임스페이스?

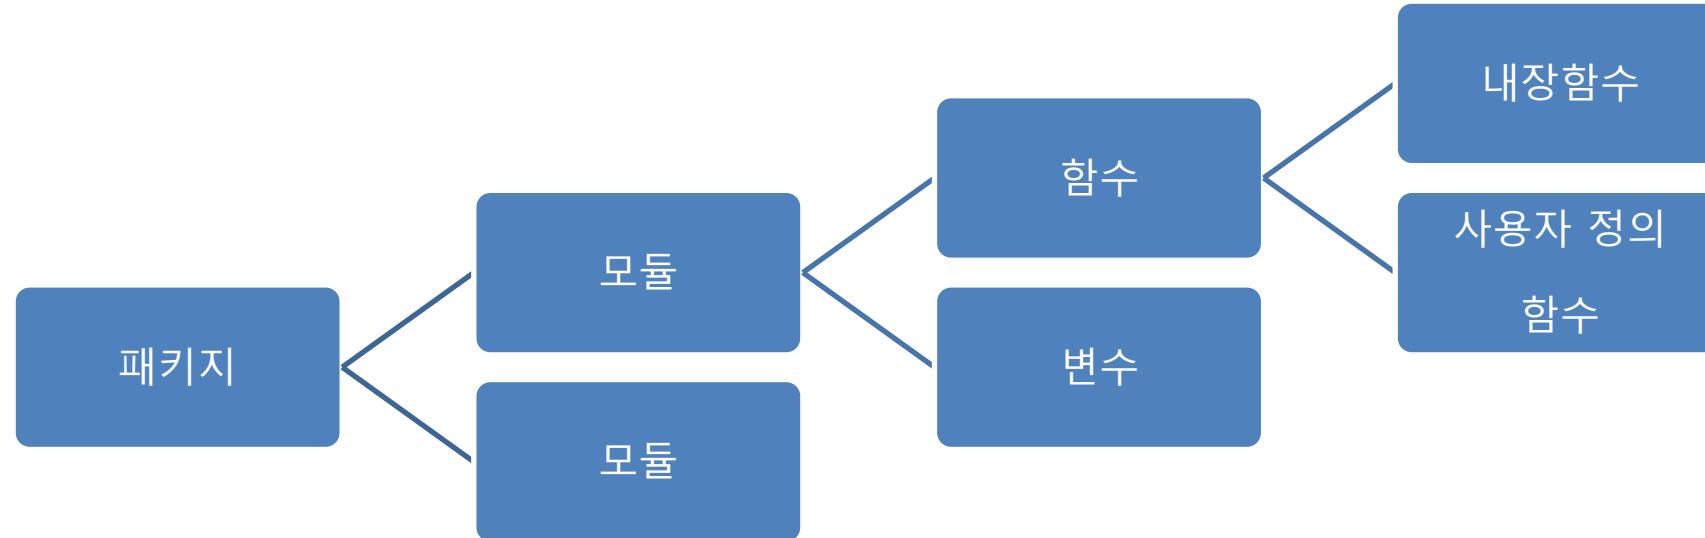
패키지1: 모듈1

패키지2: 모듈1

패키지1의 모듈1을 쓰고 싶다면!

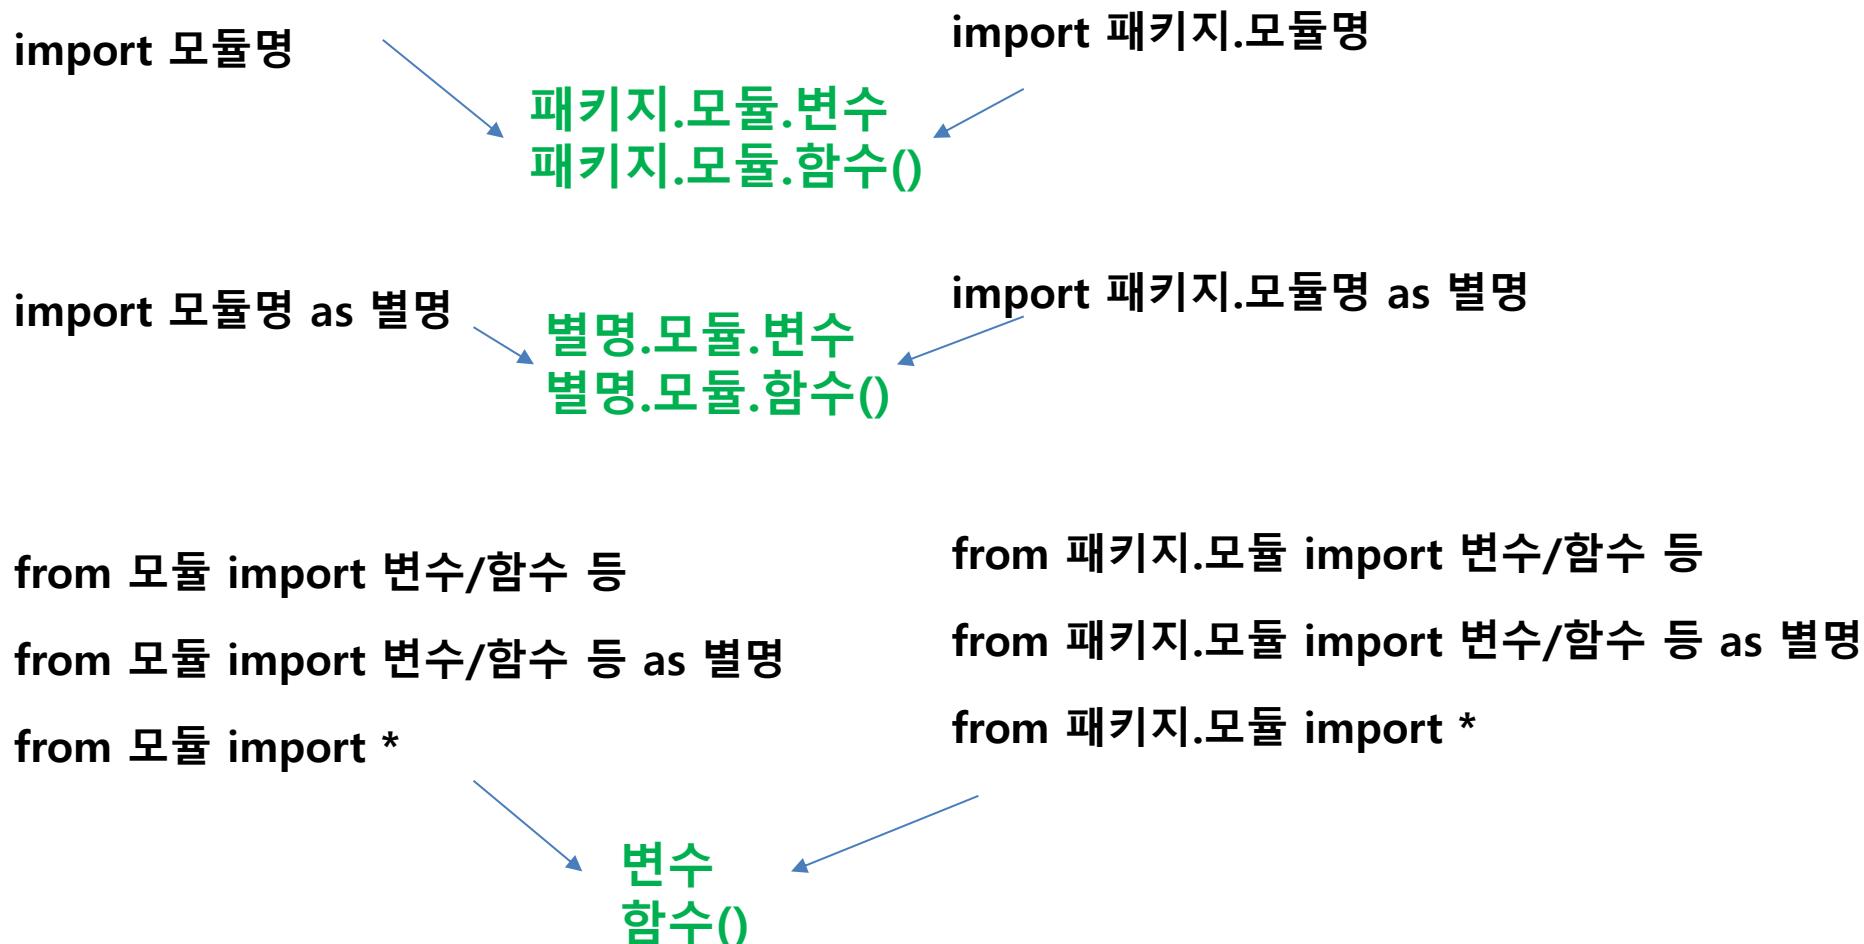
패키지1.모듈1

### 모듈, 패키지, 라이브러리



파이썬 표준 라이브러리: 파이썬에 기본으로 설치된 모듈과 패키지, 내장 함수를 통칭하여 파이썬 표준 라이브러리

### 모듈이나 패키지를 불러오는 3가지 방법

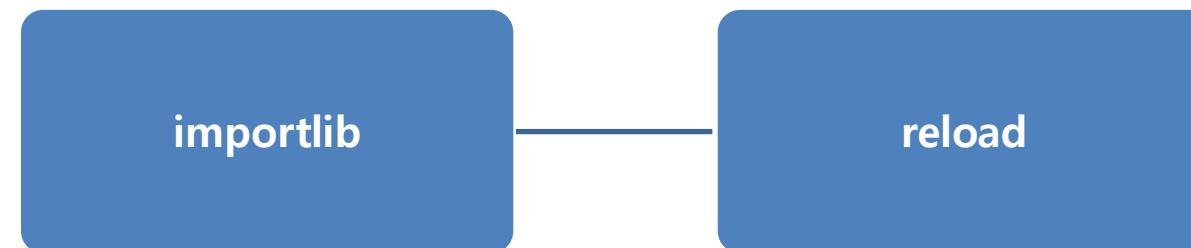


### 모듈 해제와 다시 불러오기

`del 모듈`

`import importlib`

`importlib.reload(모듈)`



### 모듈 설치하기

**pip ?**

파이썬 패키지 인덱스(Python Package Index, PyPI)의 패키지 관리 명령어

패키지 설치/삭제/업데이트 지원

쥬피터노트북에서 터미널-> **pip install 패키지 (또는 모듈) 이름**

예: **pip install mlxtend**

### 문자열(String)

따옴표, 또는 홑따옴표로 둘러싼 문자들의 집합

아무리 수치값이어도 문자열로 표현되면 더 이상 숫자가 아님!

“문자열은 어렵나요?”

‘문자열은 사용하면 안되요’

*‘I can speak English’*

‘123’

### 파일 열고 값 출력

내장함수 `open` 사용

`이름=open( 파일명, 파일열기모드)`

\*이름은 Open한 파일의 실제 값을 나타내는 역할을 함(객체)

### 파일열기모드

- 1) r: 읽기
- 2) w: 쓰기(기존 내용을 무시!)
- 3) a: 추가하기(기존 내용에 추가!)

### 파일 열고 출력의 3단계

#### 1. 파일 열고 값 출력

```
file1=open( "file1.txt", 'r')
```

```
file1=open( "file1.txt", 'w') #해당 파일명이 없다면 파일이 생성됨
```

```
file1=open( "C"\file1.txt", 'r')
```

#### 2. 열린 파일에 값 쓰기

```
f.write(값)
```

#### 3. 파일 열고 작업 후에는 파일을 닫기

```
file1.close()
```

## II. 자료구조와 파이썬 문법

파일 입력: 제공된 파일을 읽기

파일을 열은 후,

파일 객체.readline()

또는 파일 객체. readlines()를 이용

또는 파일 객체. read()를 이용

파일 읽기 3단계

1. 파일 열기 : r 모드
2. 파일 내용 읽어서 할당
3. 파일 닫기

### with 사용

```
with open( " 파일명 " , " w " ) as file1:  
    file1.write( " 파일 닫기, 거참 번거롭구먼 허허")
```

## II. 자료구조와 파이썬 문법

### 예외 처리: 오류 발생 시 적용

#### try except 사용

**try:**

    실행할 구문(들)

**except:**

    실행할 구문

**try:**

    실행할 구문(들)

**except 발생 오류 코드1:**

    실행할 구문(들)

**except 발생 오류 코드2:**

    실행할 구문(들)

**except 발생 오류 코드3:**

    실행할 구문(들)

오류 그냥 넘어가기: pass

### III. Numpy와 Pandas

#### array

- 1차원, 2차원, 3차원, ... 가능
- +,-,\*,/ 계산 지원

참고. arange 함수: 일정한 범위내 일련의 정수를 갖는 array 생성

```
import numpy as np  
arr4 = np.arange(10)          #0부터 9까지 값을 갖는 1차원 array  
arr5 = np.arange(3,10)        #3부터 9까지 값을 갖는 1차원 array
```

## array의 다차원!

1차원 / 2차원 / 3차원

```
import numpy as np
```

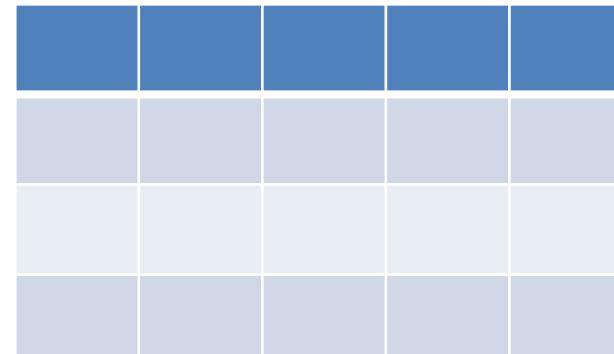
```
arr4 = np.array( [1,2,3] )
```

1차원

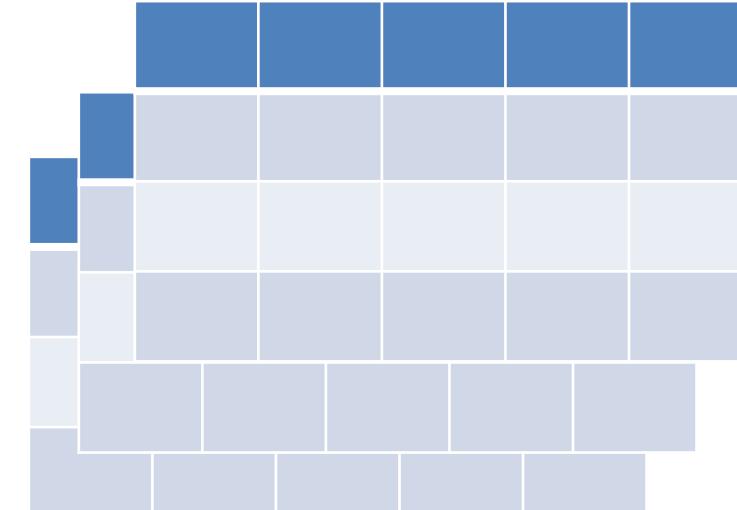


```
arr5 = np.array( [ [1,2,3], [4,5,6] ] )
```

2차원



3차원



### III. Numpy와 Pandas

## array 값들의 순서!

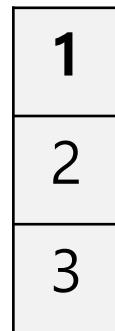
```
import numpy as np
```

```
arr4 = np.array( [1,2,3] )
```

```
arr4.tolist() #array의 list 변환 함수!
```

값의 순서가 있다!

첫 번째 값!



순서 표시: 0

순서 표시: 1

순서 표시: 2

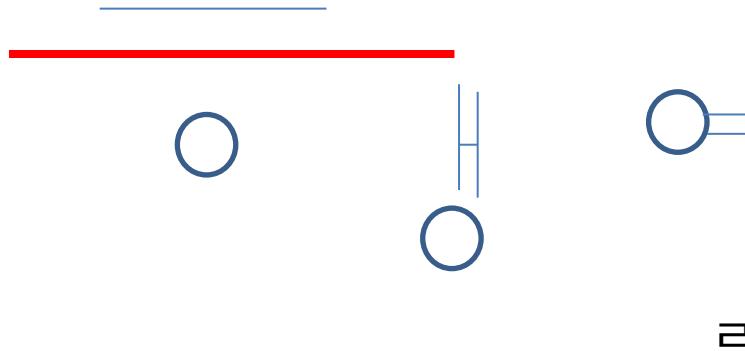
순서 표시: 3

세 번째 값!

### III. Numpy와 Pandas

#### array 값들의 순서!

```
import numpy as np  
arr5 = np.array( [ [1,2,3], [4,5,6] ] )
```




첫 번째 열! 두 번째 열! 세 번째 열!				
첫 번째 행!	1	2	3	순서 표시: 0
두 번째 행!	4	5	6	순서 표시: 1
				순서 표시: 2
순서 표시: 0	순서 표시: 1	순서 표시: 2	순서 표시: 3	

### III. Numpy와 Pandas

#### 1차원 array의 Indexing


```
import numpy as np  
arr4 = np.array( [1,2,3] )
```



arr4의 2번째 값! arr4[ 1 ]  
1번째, 3번째 값! Arr4[ [0,2] ]

## 2차원 array의 Indexing

```
import numpy as np  
arr5 = np.array( [ [1,2,3], [4,5,6] ] )  
  
arr5[ 0 , :] #첫번째 행  
arr5[ : , 1] #두번째 열  
arr5[ 0 , 1] #첫번째 행, 두번째 열
```



### III. Numpy와 Pandas

#### 다차원 array에서의 Slicing



Slicing에 사용되는 연산자!

[      ]

Slicing에 : 의 사용!

시작되는 위치: 끝나는 위치

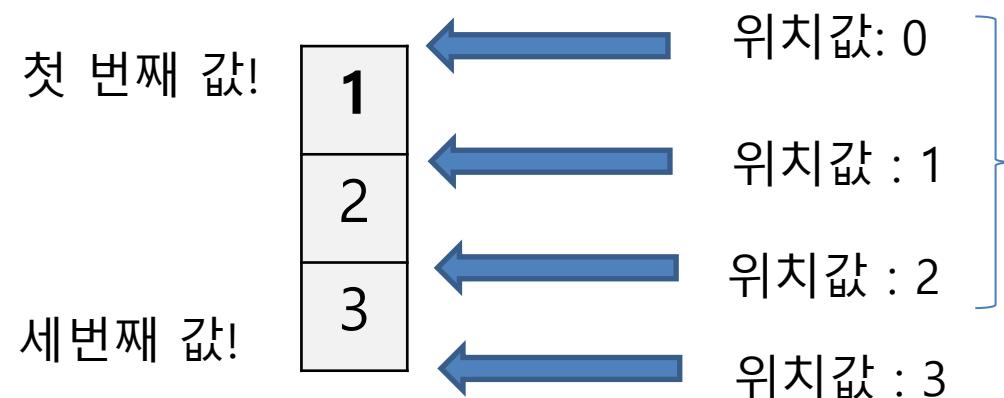
Slicing 사용 방식!

array이름[시작되는 위치값:끝나는 위치값]

### III. Numpy와 Pandas

#### 1차원 array의 slicing

```
import numpy as np  
arr4 = np.array( [1,2,3] )
```




arr4의 1~2번째 값! arr4[ 0:2 ]  
arr4의 1~2번째 값! arr4[ 0:3 ]

### III. Numpy와 Pandas

## 2차원 array의 Slicing

```
import numpy as np  
arr5 = np.array( [ [1,2,3], [4,5,6] ] )
```

arr5[ 0:1 , 1:3]      #1행, 2,3열  
arr5[ 0:2 , 1:2]      #1,2행, 2열



### III. Numpy와 Pandas

#### array

.|| array에 Scalar를 사칙연산이 가능

`arr4 * 3`

`arr5 + 1`

`arr4 -3`

`arr5 / 2`

계산 결과를 새로운 array에 할당(assignment)

`arr6 = arr4*3`

### III. Numpy와 Pandas

#### array간 연산(1차원)

.|| array 간 덧셈

**arr8+arr9**

.|| array 간 뺏셈

**arr8-arr9**

.|| array 간 곱셈

**arr8\*arr9**

.|| array 간 나눗셈

**arr8/arr9**

**arr8.size**

**arr8.shape**

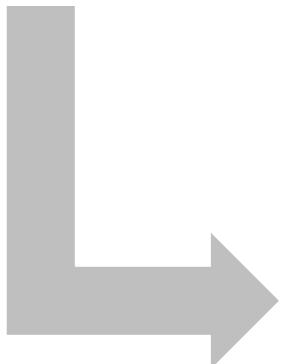
**arr8.ndim**

### III. Numpy와 Pandas

#### 주요 통계량 함수를 이용한 array 계산

통계량? 주어진 자료의 특성을 나타내는 요약값

```
import numpy as np  
  
arr12 = np.array( [3,5,2,4] )  
  
arr13 = np.array( [3.1,5.2,4.5] )  
  
arr14 = np.array( [-2,3,1,10] )
```



예: 평균, 편차, 최대, 최소값 등

평균: `np.mean( arr12 )`

표준편차: `np.std( arr12 )`

최대: `np.max( arr13 )`

최소: `np.min( arr13 )`

### III. Numpy와 Pandas

#### 주요 통계량 함수를 이용한 array 계산

그 외에도 다양한 수학함수를 지원

sum, prod, abs, sqrt, exp, log 등등...

절대값: `np.abs( arr14 )`

제곱근: `np.sqrt( arr12 )`

지수: `np.exp( arr13 )`

로그: `np.log( arr13 )`

지수? Exponential!

로그? Log!

$$e = 2.71828182846$$

*pi*와 *e*를 다음처럼 미리 정의  
 $\pi = 3.14159265359$   
 $e = 2.71828182846$

### III. Numpy와 Pandas

- **pandas**

- 데이터 처리를 위한 최고의 패키지!
- 데이터 처리 기능을 풍부하게 제공
- 빠르고 직관적인 자료 구조!

- **특징**

- DataFrame 제공
- 엑셀, CSV 등을 포함한 다양한 포맷 지원
- 데이터 정렬과 결측치 처리, 피벗 등 기능!
- 고급 인덱싱과 슬라이싱
- 데이터 합치기와 형태 변경 지원!



### III. Numpy와 Pandas

#### ➤ Pandas의 데이터 구조

##### ➤ 데이터 구조

➤ Series (1D)

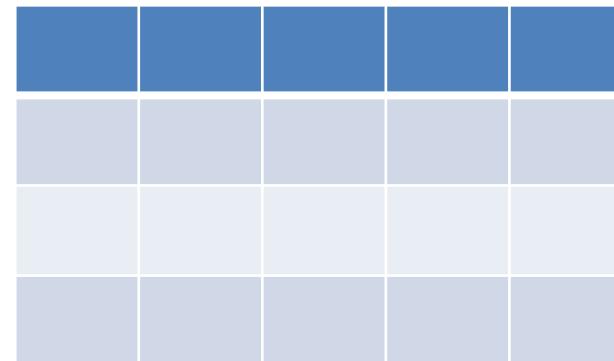
➤ DataFrame (2D)

➤ Panel (3D)


Series



DataFrame



Panel



### III. Numpy와 Pandas

#### ➤ Series

- 1차원
- Subclass of numpy.ndarray
- Index, Values를 갖음
- Index는 원하는 값을 넣을 수 있음-시계열

index	values
A	5
B	6
C	12
D	-5
E	6.7

### III. Numpy와 Pandas

#### ➤ DataFrame

- 행과 열이 있는 2차원
- 열마다 값의 타입이 다를 수 있음!
- 행, 열 모두 인덱스
- 크기가 바뀔 수 있음-행, 열 추가 및 삭제!

		columns	국	영	수	출석
		index				
갑 을 병 정 무	→	100	40	55	True	
	→	90	70	33	True	
	→	50	50	88	False	
	→	70	78	99	False	
	→	94	44	88	False	
	→					


### III. Numpy와 Pandas

- **Series**
  - pandas에서 제공하는 1차원 자료 구조, 연산, 인덱싱, 슬라이싱을 포함해 다양한 기능을 지원
- **Series의 인덱싱과 슬라이싱**
  - Series는 Index와 Value를 나누어 활용할 수 있으며, 이때 Index Label이나 Array를 이용한 인덱싱, 슬라이싱을 지원
- **Series 연산**
  - 수치 계산 및 벡터화 계산을 지원하며, Series 간 연산 시 같은 Index 값이 계산

### III. Numpy와 Pandas

#### ➤ Series

- 1차원
- Index, Values를 갖음



### III. Numpy와 Pandas

#### ➤ Series 생성하기

- 1차원 시퀀스 형태의 자료구조(예: 리스트 array)로 부터 생성 가능
- **Series = Value + Index**
- Index Label: Index에 원하는 값을 지정할 수 있음

```
import numpy as np
import pandas as pd

S1 = pd.Series( [1,2,3] )

S2 = pd.Series( np.array([1,2,3]) )

S3 = pd.Series( [80,90,75], index=["가","나","다"] )
```

- Series명.values, 예를 들어 S1.values
- Series명.index, 예를 들어 S3.index

### III. Numpy와 Pandas

#### ➤ Series 인덱싱과 슬라이싱

- Index Label을 활용해서 원하는 범위의 값을 선택할 수 있음
  - Index가 지정 안 된 경우: 첫번째값이 0부터 시작하는 정수 index를 갖음
  - Index가 지정된 경우: 별도로 지정한 Index Label을 사용할 수 있으며, 첫번째값이 0부터 시작하는 정수 index도 사용할 수 있음

```
S4 = pd.Series( [1,2,3,4,5] )  
  
S5 = pd.Series( [1,2,3,4,5], index=["a","b","c","d","e"] )  
  
S4[0] # S4의 첫번째 값  
S4["a"] # 오류, S4에는 별도로 지정된 index 없음  
  
S5[0] # S5의 첫번째 값  
S5["a"] # S5의 첫번째 값  
  
S4[ 0:3 ] #S4의 1~4번째 값  
S5[ ["a", "c", "e"] ] #S5의 1,3,5번째 값 출력
```

### III. Numpy와 Pandas

#### ➤ Series 연산

##### ➤ Series는 수치 계산을 지원

➤ +,-,\*,/

##### ➤ Series 간 연산은 같은 Index 값끼리 계산

```
S4 = pd.Series( [1,2,3,4,5], index=["a","c","d","b","e"] )
```

```
S5 = pd.Series( [1,2,3,4,5], index=["a","b","c","d","e"] )
```

S4+S5

S4

values	index
1	a
2	c
3	d
4	b
5	e

S5

index	values
a	1
b	2
c	3
d	4
e	5

### III. Numpy와 Pandas

- **DataFrame**
  - pandas에서 제공하는 2차원 자료 구조, 연산, 인덱싱, 슬라이싱을 포함해 다양한 기능을 지원
- **DataFrame의 인덱싱과 슬라이싱**
  - DataFrame은 행은 슬라이싱을, 열은 인덱싱을 지원할 수 있으며, 추가적인 함수를 통해 인덱싱과 슬라이싱을 자유롭게 사용 가능.
- **DataFrame 활용**
  - 수치 계산 및 벡터화 계산을 지원하며, 자료처리를 위한 다양한 함수를 활용할 수 있음

### III. Numpy와 Pandas

#### ➤ DataFrame의 특징!

- 2D table with rows and column labels
- column 별로 서로 다른 dtype을 가질 수 있음
- 행과 열 Index Label을 지원

index	columns	foo	bar	baz	qux
A	→	0	x	2.7	True
B	→	4	y	6	True
C	→	8	z	10	False
D	→	-12	w	NA	False
E	→	16	a	18	False

### III. Numpy와 Pandas

- DataFrame의 더 많은 특징!
  - 데이터의 reshaping 및 pivoting
  - Label 활용 슬라이싱과 인덱싱, 부분집합 구하기가 쉬움
  - Group by 엔진 지원: Data Aggregation/ Data Transformation

- Data Alignment
  - "Outer join"을 지원: 두 데이터프레임의 행 또는 열 Index를 기준으로 계산!

$$\begin{array}{|c|c|} \hline B & 1 \\ \hline C & 2 \\ \hline D & 3 \\ \hline E & 4 \\ \hline \end{array} + \begin{array}{|c|c|} \hline A & 0 \\ \hline B & 1 \\ \hline C & 2 \\ \hline D & 3 \\ \hline \end{array} = \begin{array}{|c|c|} \hline A & NA \\ \hline B & 2 \\ \hline C & 4 \\ \hline D & 6 \\ \hline E & NA \\ \hline \end{array}$$

### III. Numpy와 Pandas

#### ➤ DataFrame 생성하기

- 2차원 형태의 자료구조(예: 리스트의 리스트, 2차원 array)와 Dictionary(Value가 1차원 자료구조인 경우)로 부터 생성 가능
- **DataFrame = Series + Series + Series ....**
- 행과 열의 Index Label: Index에 원하는 값을 지정할 수 있음!

```
import numpy as np
import pandas as pd

df1 = pd.DataFrame( [[1,2,3], [1,2,3]], columns=['a','b'], index=['r1','r2','r3'] )
df2 = pd.Series( np.array([[1,2,3], [1,2,3]]), columns=['a','b'],
index=['r1','r2','r3'])
raw_data = {'col0': [1, 2, 3, 4],
            'col1': [10, 20, 30, 40],
            'col2': [100, 200, 300, 400]}
df3 = pd.Series( raw_data )
```

- DF명.values, 예를 들어 df1.values
- DF명.index, 예를 들어 df1.index
- DF명.columns, 예를 들어 df1.columns

### III. Numpy와 Pandas

#### ➤ DataFrame의 인덱싱과 슬라이싱

- 인덱싱: 열 이름을 지정, 복수인 경우 리스트로 묶어서 지정
- 슬라이싱: 선택을 원하는 행을 슬라이싱 / 단 행 단위에 인덱싱 사용 불가

```
#행  
df1[ 0 ] #오류  
df1[ 0:1 ]
```

```
#열  
df1['a']  
df1[['a','c']]
```

### III. Numpy와 Pandas

#### ➤ DataFrame 활용

- .head(), .describe() 등의 유용한 기능 활용
- 두 데이터프레임의 수치 계산은 같은 인덱스의 해당되는 컬럼끼리 계산!
  - +,-,\*,/

```
df3 = pd.DataFrame( [[1,2,3], [1,2,3]], columns=['a','b','c'], index=['r2','r3'] )  
df1+df3
```

